RAPPORT TP6 — Représentation du texte pour la classification de sentiments

1. Cadre expérimental

Le corpus utilisé est le dataset **IMDb Movie Reviews** (50 000 critiques de films en anglais), avec une variable cible binaire : sentiment positif (1) ou négatif (0). Les classes sont parfaitement équilibrées (25 000 par classe), ce qui garantit des métriques fiables. L'ensemble du corpus a été utilisé pour les méthodes lexicales ; un sous-échantillon a été nécessaire pour BERT. Pour assurer une comparaison équitable, un cadre commun a été maintenu : même découpage train/test (80%/20%, stratifié, random_state=42), même classifieur (Régression Logistique), mêmes métriques (Accuracy, F1 macro, Matrice de confusion).

2. Exploration et prétraitement

Les avis contiennent en moyenne **231 mots** avec un écart-type élevé (171), révélant une forte hétérogénéité : de 4 mots minimum à 2470 maximum. Les longueurs sont similaires entre classes positives et négatives, confirmant l'absence de biais. Le corpus contient du bruit textuel (balises HTML, ponctuation variée) qui a été traité par la fonction nettoyer_texte() : conversion en minuscules, suppression des balises HTML, suppression des caractères non alphabétiques sauf apostrophes, normalisation des espaces.

Les choix de prétraitement ont été justifiés : les stopwords ont été supprimés (non informatifs), les négations conservées ("not bad" ≠ "bad"), les apostrophes maintenues ("don't" garde son sens), et la normalisation en minuscules appliquée pour éviter les doublons.

3. Méthodes testées et résultats

3.1 Bag of Words (BoW)

BoW convertit chaque document en vecteur de fréquences lexicales (vocabulaire limité à 10 000 mots). Il conserve la présence et la fréquence des mots, mais perd l'ordre, le contexte et les relations sémantiques. Il reste performant sur IMDb car les critiques sont longues et contiennent des mots de sentiment explicites ("terrible", "brilliant"). Sa limite principale : il ne peut pas interpréter la négation — "not good" donne une orientation positive erronée car "not" et "good" sont traités comme deux dimensions indépendantes.

Résultats : Accuracy = 0.8834 | F1 macro = 0.8834 | Temps entraînement = 67.89s

3.2 N-grams (bigrammes)

Les bigrammes (ngram_range=(1,2)) capturent des séquences de 2 mots consécutifs, permettant de traiter partiellement la négation. Vérification dans le vocabulaire : "not good", "really bad" et "highly recommend" sont présents dans le vocabulaire bigrammes mais absents du vocabulaire BoW, ce qui confirme l'apport. "waste of time" reste absent

(trigramme, 3 mots). Les trigrammes ne sont pas retenus car leur rareté dans le corpus crée du bruit et risque d'overfitting.

Résultats : Accuracy = 0.8881 | F1 macro = 0.8881 (+0.47 pts vs BoW)

3.3 TF-IDF

TF-IDF pondère chaque terme par sa fréquence dans le document (TF) et sa rareté dans le corpus (IDF), réduisant le poids des mots ubiquitaires ("the", "is") et valorisant les mots discriminants ("atrocious", "brilliant"). TF-IDF est meilleur que BoW non pas parce qu'il comprend le texte, mais parce qu'il réduit le bruit des mots peu informatifs. Il ne capture ni le contexte ni les relations sémantiques. C'est la combinaison avec les bigrammes qui lui permet de traiter les cas de négation.

Résultats : Accuracy = 0.9034 | F1 macro = 0.9034 | Temps entraînement = 49.27s

Analyse des erreurs : 516 faux positifs (critiques négatives avec ironie ou sarcasme) et 450 faux négatifs (expressions comme "wickedly funny" mal interprétées). Les deux types d'erreurs sont proches, confirmant l'absence de biais systématique.

3.4 Word2Vec

Word2Vec représente chaque mot par un vecteur dense de 100 dimensions, appris à partir du contexte (sg=1, window=5). Des mots apparaissant dans des contextes similaires ont des vecteurs proches — c'est l'hypothèse distributionnelle. Le document est représenté par la **moyenne** des vecteurs de ses mots, ce qui entraîne une perte importante : l'ordre des mots disparaît ("not good" ≈ "good not"), tous les mots ont le même poids, et les marqueurs de négation sont noyés. Les mots rares (min_count=2) ne sont pas appris.

Résultats : Accuracy = 0.8647 | F1 macro = 0.8647 | Temps entraînement classifieur = 0.97s

Paradoxe notable : Word2Vec capture mieux la sémantique que TF-IDF, mais donne une performance inférieure sur cette tâche, car la moyenne des vecteurs efface les informations discriminantes pour le sentiment.

3.5 FastText

FastText étend Word2Vec en décomposant chaque mot en n-grammes de caractères ("movie" → "mo", "ov", "vi"…). Même un mot rare ou mal orthographié partage des n-grammes avec ses variantes connues, ce qui le rend robuste aux OOV et aux fautes d'orthographe. Cette propriété est particulièrement utile dans les langues à morphologie riche (arabe, turc, finnois) mais son avantage est limité sur IMDb, corpus anglais bien orthographié.

Résultats : Accuracy = 0.8653 | F1 macro = 0.8653 | Temps entraînement classifieur = 1.11s

3.6 BERT / DistilBERT

BERT produit des embeddings contextuels : un même mot peut avoir des vecteurs différents selon la phrase. Grâce à son attention bidirectionnelle, "not good" reçoit un vecteur différent de "good" seul — la négation est correctement prise en compte. BERT est pré-entraîné sur une tâche de Masked Language Modeling (MLM), lisant le contexte gauche et droit simultanément. DistilBERT (40% de paramètres, ~97% des performances de BERT) a été utilisé pour des raisons de ressources. Les résultats complets n'ont pas pu être obtenus sans GPU.

4. Tableau comparatif

Méthode	Type	Accuracy	F1 Macro	Temps classifieur
BoW	Lexicale	0.8834	0.8834	67.89s
N-grams (1,2)	Lexicale + ordre local	0.8881	0.8881	—
TF-IDF (1,2)	Lexicale pondérée	**0.9034**	**0.9034**	49.27s
Word2Vec	Embedding statique	0.8647	0.8647	0.97s
FastText	Embedding sous-mots	0.8653	0.8653	1.11s
BERT	Embedding contextuel	+0.92	+0.92	Très élevé

TF-IDF domine les méthodes lexicales. Word2Vec et FastText, malgré leur richesse sémantique, restent inférieurs à TF-IDF sur ce corpus, car la moyenne des vecteurs efface les informations discriminantes. Les embeddings sont en revanche 50x plus rapides à utiliser pour le classifieur.

5. Questions de synthèse

Quelle méthode est la plus adaptée au corpus IMDb ?

TF-IDF avec bigrammes est la méthode la plus adaptée parmi celles testées. Le corpus IMDb est riche en mots de sentiment explicites que TF-IDF pondère correctement ; les bigrammes capturent les négations fréquentes ; et le rapport performance/coût est optimal (90.34% pour 49 secondes). BERT serait théoriquement supérieur sur les cas d'ironie et d'ambiguïté, mais son coût de calcul est prohibitif sans GPU.

La meilleure méthode est-elle la plus simple à interpréter ?

Non. BoW est le plus interprétable (chaque dimension = fréquence d'un mot) mais le moins performant. TF-IDF reste lisible via les coefficients du classifieur. Word2Vec et FastText produisent des vecteurs denses peu interprétables. BERT (768 dimensions contextuelles) est

le moins interprétable. Il existe une tension fondamentale : plus un modèle est expressif, moins il est interprétable.

Quel compromis entre précision, coût et explicabilité ?

- Déploiement rapide et explicabilité importante → **TF-IDF + bigrammes** (~90%)
- Prototype minimal avec ressources très limitées → **BoW** (~88%)
- Haute performance avec GPU disponible → **BERT fine-tuné** (~93-95%)
- Corpus bruité ou non standardisé → **FastText** (~87%)

Pour ce TP, TF-IDF + bigrammes est le choix recommandé : meilleure performance sans GPU, interprétable, et temps d'entraînement raisonnable.

Le classement changerait-il avec plus de données ?

Oui. TF-IDF et BoW bénéficieraient marginalement de plus de données : ils restent fondamentalement limités par leur incapacité à capturer le contexte. Word2Vec et FastText bénéficieraient davantage, car des embeddings appris sur plus de contextes seraient de meilleure qualité et pourraient rejoindre TF-IDF. BERT, déjà pré-entraîné sur des milliards de mots, gagnerait peu. En conclusion, avec beaucoup plus de données, les méthodes neuronales devraient naturellement dominer, car leur capacité expressive supérieure serait pleinement exploitée.